



UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO DE CIÊNCIAS, TECNOLOGIAS E SAÚDE
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

Nícolas Sanson Giaboeski

**Validação de um sensor de eletromiografia de superfície de baixo custo e
integração com inteligência artificial para reabilitação**

Araranguá
2025

Nícolas Sanson Giaboeski

**Validação de um sensor de eletromiografia de superfície de baixo custo e
integração com inteligência artificial para reabilitação**

Relatório Técnico do Curso de Graduação em Engenharia de Computação do CENTRO DE CIÊNCIAS, TECNOLOGIAS E SAÚDE da Universidade Federal de Santa Catarina para a Conclusão da Disciplina de Projeto Integrador II.

Orientador: Prof. Jim Lau, Dr.

Coorientador: Prof. Substituto. Lucas Bertinetti Lopes.

Araranguá

2025

Validação de um sensor de eletromiografia de superfície de baixo custo e integração com inteligência artificial para reabilitação

Nícolas Sanson Giaboeski

RESUMO

O uso de aparelhos capazes de realizar uma medição precisa de ativação muscular durante a fase de reabilitação pós-cirúrgica é muito significativo, pois mostram diversos parâmetros que não podem ser avaliados de outras maneiras. Entretanto, muitas clínicas ou centros de reabilitação não possuem capacidade de adquirir um aparelho comercial que consiga fazer uma leitura de dados eficiente. Tendo isso em vista, o presente trabalho busca validar o uso de um sensor de eletromiografia de baixo custo adicionado à outros componentes eletrônicos através de testes e comparações com um aparelho de eletromiografia comercial. Por fim, o trabalho almeja a utilização deste sistema para coleta de dados e utilização de técnicas de inteligência artificial para detecção de padrões, anomalias e auxílio na reabilitação.

Palavras-chave: eletromiografia de superfície, baixo custo, reabilitação, inteligência artificial.

Validação de um sensor de eletromiografia de superfície de baixo custo e integração com inteligência artificial para reabilitação

Nícolas Sanson Giaboeski

ABSTRACT

The use of devices capable of accurately measuring muscle activation during the post-surgical rehabilitation phase is highly significant, as they provide various parameters that cannot be assessed through other means. However, many clinics or rehabilitation centers are not able to acquire commercial equipment capable of efficient data acquisition. With this in mind, the present work aims to validate the use of a low-cost electromyography sensor combined with other electronic components through tests and comparisons with a commercial electromyography device. Finally, this work aims to use the system for data collection and the application of artificial intelligence techniques for pattern recognition, anomaly detection, and support in rehabilitation.

Keywords: surface electromyography, low-cost, rehabilitation, artificial intelligence.

1 INTRODUÇÃO

A eletromiografia (EMG) é uma técnica amplamente utilizada para registrar a atividade elétrica dos músculos, podendo ela ser feita de duas formas principais: invasiva, através de eletrodos inseridos diretamente no músculo esquelético; ou não invasiva, conhecida como eletromiografia de superfície, na qual os eletrodos são posicionados sobre a pele, sem nenhum tipo de inserção (J. M. Dick et al., 2024). A atividade elétrica captada pela EMG reflete os sinais enviados pelos neurônios motores a fim de controlar a contração muscular, que podem ser detectados até mesmo antes da ação física ocorrer (J. M. Dick et al., 2024). A medição da atividade muscular fornece informações sobre a capacidade de recrutamento de unidades motoras, fadiga e sinergia, além de indicar evidências da eficácia do plano de reabilitação (Campanini et al., 2020).

Esta técnica fornece informações detalhadas das propriedades anatômicas do músculo esquelético, sendo muito útil em diversos contextos, como no acompanhamento de pessoas que sofrem com alguma disfunção muscular, reabilitação e *biofeedback* (Campanini et al., 2020; Lucas, 2023; Merletti et al., 2023). Embora a eletromiografia de superfície forneça informações menos detalhadas em comparação com a técnica invasiva (Boyer et al., 2023), ela ainda é uma ferramenta eficaz para a obtenção de dados relevantes sobre o padrão temporal da atividade muscular e suas principais características (Lucas, 2023).

A grande dificuldade que persiste nessa área de estudo e que muitos trabalhos buscam resolver é a eficiência que um sistema de eletromiografia de baixo custo pode oferecer e se é possível substituí-lo por um sistema comercial de padrão ouro (Bawa; Banitsas, 2022; Fuentes Del Toro et al., 2019; Heywood et al., 2018; Machetanz et al., 2022). Buscar uma solução para o quesito de custo e acessibilidade à esse tipo de material fundamental em cenários de reabilitação tem sido um impasse devido à necessidade de construção de sistemas customizados com componentes diversos (Heywood et al., 2018). Um aparelho de eletromiografia padrão ouro é comercializado por um valor muito alto, se tornando uma ferramenta não acessível para muitas clínicas ou centros de reabilitação (Bawa; Banitsas, 2022; Fuentes Del Toro et al., 2019; Heywood et al., 2018; Machetanz et al., 2022; Merletti; Cerone, 2020). Os trabalhos que realizaram um sistema de sEMG de baixo custo destacam a necessidade integrar componentes diversos para superar as limitações de hardware, tais como o uso de microcontroladores como Arduino Nano, Arduino Mega e ATmega328 para gerir a captação de dados (Fuentes Del Toro et al., 2019; Tanweer; Halonen, 2019; Universiti Teknologi Malaysia et al., 2023), unidades de medição inercial (IMUs) que incluem acelerômetros, giroscópios e magnetômetros para melhorar o reconhecimento da intenção de movimento (Tanweer; Halonen, 2019), e o uso de amplificadores operacionais ou amplificadores de instrumentação para amplificação do sinal, condicionamento e rejeição de ruídos, assim como o uso de conversores AD para uma melhor resolução de bits do sinal (Machetanz et al., 2022).

A tecnologia avançada e a robótica têm sido grandes aliados do cenário de reabilitação nos últimos anos, porém, a inteligência artificial é vista com maus olhos por ser uma técnica que ameaça as profissões da área da saúde (Campanini et al., 2020). Apesar disso, ela é uma ferramenta que deveria ser introduzida como um

ótimo recurso auxiliar para análise de dados, tais como os de eletromiografias (Campanini et al., 2020).

1.1 OBJETIVOS

Levando em consideração o impacto que o uso da EMG tem na fase de reabilitação e a inacessibilidade que um sistema desses possui, o presente trabalho tem como objetivo o uso de um hardware comercial de eletromiografia de superfície adicionado a um microcontrolador para adquirir, armazenar e mostrar dados de eletromiografia, assim como a integração com outros sensores. Apesar de a eletromiografia de superfície fornecer uma medição da função muscular em tempo real menos fiel que a técnica invasiva, ela foi escolhida por ser justamente uma técnica menos agressiva. Entretanto, continua sendo uma ferramenta que permite a análise do desempenho, fadiga, coordenação e recrutamento de músculos durante movimentos. Ademais, é uma ferramenta essencial tanto clínica quanto experimental, contribuindo para diagnósticos precisos, intervenções personalizadas e melhor qualidade de reabilitação.

Além disso, considerando que o modelo de baixo custo possui limitações, o trabalho busca utilizar técnicas como a integração de unidades de medição inercial para promover uma coleta de dados mais fiel ao movimento executado, como relata (Gonzales-Huisa et al., 2023).

Para verificar a eficiência do sistema de baixo custo, ele será comparado com um aparelho comercial padrão ouro que é utilizado em clínicas com frequência. Com a validação do funcionamento adequado de um sistema de baixo custo, o objetivo final é a utilização do mesmo em clínicas para realizar extração e coleta de dados em pacientes reais com a finalidade de confeccionar uma ferramenta baseada em técnicas de inteligência artificial que servirá de auxílio na interpretação geral da ativação muscular, detectando anomalias, padrões e recrutamento de músculos auxiliares (Pérez-Reynoso et al., 2022; Qamar et al., 2024), a fim de fornecer sugestões de análise ou recomendações de exercícios específicos para melhorar a eficiência da reabilitação.

Os objetivos específicos são dados por:

- Projeção do uso dos componentes para coleta e armazenamento de dados iniciais referentes ao sinal de contrações voluntárias do Biceps Brachii através da integração entre o sensor e um microcontrolador ESP32;
- Testes relacionados ao dados coletados pelo sensor de sEMG e análise de eficiência/fidelidade comparando-o com um aparelho comercial;
- Integrar ao sistema soluções propostas (IMUs e conversor AD externo ao microcontrolador) e verificar se há uma melhora na eficiência/fidelidade;
- Projetar um modelo de uso simplificado;
- Avaliar as possibilidades de uso em clínicas (criar um comitê de ética);
- Integrar técnicas de inteligência artificial e verificar sua eficácia como ferramenta para melhoria da reabilitação.

2 FUNDAMENTAÇÃO TEÓRICA

No presente capítulo serão abordados assuntos para compreender um pouco do que são os sinais de eletromiografia de superfície, assim como compreender os componentes do sistema proposto.

Para que o capítulo tenha um fluxo adequado, ele terá uma introdução na Seção 2.1 de como funciona a anatomia e a fisiologia do sistema muscular esquelético, resumindo como é gerado o sinal interpretado pelo sensor de eletromiografia.

Na Seção 2.2, será resumido o funcionamento do sistema, abordando a captação elétrica feita pelos eletrodos do sensor e como o microcontrolador escolhido (ESP32) trata essa informação.


Na seção 2.3 é abordada a interferência da pele como impedância no sinal sEMG.

Na seção 2.4 é comentado sobre o projeto SENIAM e as propostas que ele desenvolveu para a eletromiografia de superfície.

2.1 Base anatômica

As células nervosas e células dos músculos são capazes de gerar impulsos eletroquímicos, os quais transmitem sinais por toda a membrana dos nervos e músculos. Os sinais nervosos são os chamados *potenciais de ação*, que são as alterações de potencial negativo e positivo que ocorrem ao longo da fibra nervosa. Para que haja um controle de polaridade sobre o potencial de ação, há um agente que provoca despolarização e repolarização, que é o *canal de sódio regulado pela voltagem*, que atua com auxílio do *canal de potássio regulado pela voltagem*. O canal de sódio atua com um comportamento de duas comportas, enquanto o canal de potássio atua como uma única comporta, cada um fazendo o controle dos íons respectivos. Este comportamento pode ser verificado pela Figura 1 (Hall, 2015).


Figura 1 – Comportamento dos canais de sódio e potássio.



Fonte: adaptado de (Hall, 2015).

O ser humano possui aproximadamente 40% do seu corpo composto por músculo esquelético, e este por sua vez, é composto por numerosas fibras que variam de 10 a 80 micrômetros cada. A partir da Figura 2, é possível visualizar uma prévia da divisão do músculo esquelético. A contração muscular começa com os potenciais de ação viajando pelo nervo motor, que é localizado na medula espinhal, até as suas terminações (fibras nervosas que inervam as fibras musculares). Em cada fibra, o nervo secreta uma pequena quantidade de *acetilcolina*, que é uma substância neurotransmissora. Essa substância abre canais de cátion nas fibras, permitindo uma grande difusão de íons sódio para o lado interno da membrana que envolve a fibra muscular, o que tem como consequência a despolarização local e abertura de canais de sódio, desencadeando o potencial de ação por toda a membrana. A despolarização da membrana é o que faz com que haja uma eletricidade do potencial de ação fluindo pelo centro da fibra muscular, o processo no geral é referido como *impulso nervoso* ou *muscular* (Hall, 2015).

Figura 2 - Divisão do músculo esquelético simplificada.



Fonte: adaptado de (Hall, 2015).

2.2 Eletrodos e microcontrolador

Os eletrodos de eletromiografia de superfície podem ser definidos como sensores de atividade elétrica dos músculos ou como transdutores de corrente iônica que sai do tecido (pele) e são convertidos para corrente elétrica sendo conduzidos por fios metálicos. Os modelos de eletrodos possuem diversas dimensões físicas, tamanhos, tecnologias e são constituídos por diferentes materiais (Merletti et al., 2009). Vale ressaltar que os eletrodos detectam potenciais no espaço extracelular, ou seja, não fornecem informações sobre correntes transmembranas (Merletti; Cerone, 2020).

O sinal de sEMG é, resumidamente, a atividade elétrica do músculo em contração, e essa diferença de potencial detectada na superfície da pele é influenciada pela impedância do músculo que circula, do tecido subcutâneo e da pele (McManus; De Vito; Lowery, 2020). Esse sinal representa a soma algébrica dos potenciais de ação da unidade motora que são detectados na pele (Campanini et al., 2020).

2.3 Impedâncias

Os íons que fluem na membrana das fibras musculares formam uma taxa de fluxo de carga, a qual é chamada de corrente elétrica, que por sua vez, é medida em Amperes (carga elétrica por segundo) (McManus et al., 2020). Essa corrente iônica flui no tecido (pele), e pode ser captada pelos eletrodos que estão em contato com a camada córnea da pele, a parte mais externa da epiderme, com espessura de 15 a

20 micrômetros, contribuindo fortemente na impedância entre a interface eletrodo-pele (Merletti; Cerone, 2020).

2.4 Padrão SENIAM

Em 1999, um projeto europeu com o nome de “Surface Electromyography for Non Invasive Assessment of Muscles”, hoje conhecido pela sigla SENIAM, disponibilizou uma base de recomendação para o uso de aparelhos de eletromiografia de superfície, definindo as diretrizes da posição dos eletrodos, processamento de sinal, técnicas de modelação e relatório de dados (Merletti et al., 2023).

3 MATERIAIS E MÉTODOS

O primeiro passo foi realizar a escolha do material que constituirá o sistema. Começando pelo sensor de eletromiografia de superfície. Duas opções principais foram disponibilizadas, sendo elas o Muscle Sensor v3 da Advancer Technologies e o Sen0240 Analog EMG Sensor by OYMotion feito em colaboração entre OYMOtion e DFRobot. O modelo que aparentou ser mais robusto foi o Sen0240, logo, ele foi escolhido. Para o tratamento dos sinais que o sensor captura, foi escolhido o microcontrolador ESP32, mais especificamente o modelo YD-ESP32-23 desenhado pelo VCC-GND Studio, sendo um modelo potente por possuir 16MB de memória flash e 8MB de memória de acesso aleatório pseudostática (PSRAM). Para realizar as comparações entre o sistema de baixo custo e um sistema comercial, foi disponibilizada a oportunidade de verificar o funcionamento do New Miotool da Miotec.

3.1 Comparação de especificações técnicas

A comparação entre os dois modelos começa com especificações relacionadas ao próprio hardware e capacidade de processamento de cada um. O sEMG de baixo custo proposto possui algumas limitações quando se trata do sinal em si. Dentre essas limitações, as principais são que o sensor de eletromiografia da DFRobot em conjunto com a OYMotion é um sensor de canal único, enquanto o New Miotool possui opções de 2, 4 ou até 8 canais para coletar dados, ou seja, o sensor de baixo custo é limitado a coletar dados de apenas um grupamento muscular, enquanto o padrão ouro consegue interpretar sinais de vários pontos. Vale ressaltar que a posição que os sensores foram testados seguem o padrão SENIAM.

A segunda limitação vista durante a fase de comparação é que o modelo de baixo custo necessita de um microcontrolador para poder processar e interpretar os dados lidos, e essa necessidade de um microcontrolador externo influencia diretamente na resolução do sinal lido. Isso acontece porque a leitura do sinal do sensor é feita em uma porta do microcontrolador que funciona como um conversor AD, o qual possui uma resolução de sinal máxima de 12 bits, enquanto o dispositivo do New Miotool tem um teto em 16 bits de resolução.

Por fim, a última comparação de relevância feita é na taxa de amostragem de cada modelo, onde o sensor da DFRobot e OYMotion possui limite de banda de 1kHz, o ESP32 é capaz de oferecer uma taxa de amostragem no seu conversor AD bem superior a 2kHz (até 200kHz), o que confere com a regra de Nyquist (a taxa de amostragem deve ser no mínimo o dobro do sinal), enquanto o modelo da Miotec possui uma taxa de amostragem de 2000 dados por segundo.

A comparação geral do sensor de eletromiografia de superfície de baixo custo e um aparelho comercial pode ser observada na Tabela 1.

Tabela 1 – Comparação entre sensor de baixo custo e aparelho comercial

Característica	Sen0240	New Miotool
Canais	1	2,4 ou 8
Amostras por segundo	1000	2000
Preço	USD 50,00	Só foi possível encontrar um modelo usado em um centro de vendas (Mercado Livre) por aproximadamente USD 4300,00
Memória Flash	16MB (Referente ao ESP32 utilizado)	4MB
Resolução	12 bits (Referente ao ESP32 utilizado)	16 bits
Endereço das informações	https://wiki.dfrobot.com/Analog_EMG_Sensor_by_OYMotion_SKU_SEN0240#target_0	https://miotec.com.br/produtos/new-miotool/

Imagem



3.2 Configurações iniciais


Apesar de o sEMG de baixo custo apresentar limitações quanto às especificações físicas, foram definidos diversos parâmetros para validar a possibilidade de uso do sensor de baixo custo para formar uma base sólida de informações que possam ser interpretadas por profissionais da saúde.

Para isso, o sensor de sEMG foi conectado ao microcontrolador ESP32, seguindo os padrões de conexão com ground, alimentação direta do pino de 3.3V e conversor AD do pino 4, além de manter contato entre o aterramento e a pele para diminuição de ruído. A primeira visualização feita foi através da ferramenta Arduino IDE, a qual possui a ferramenta Serial Plotter e seguindo o código padrão proposto no site da DFRobot. Algumas alterações necessárias que são indicadas na documentação do código foram feitas, como a mudança da variável NOTCH_FREQ_50HZ para NOTCH_FREQ_60HZ, correspondendo à frequência padrão da rede elétrica do Brasil. Além disso, a variável correspondente à taxa de amostragem foi ajustada com SAMPLE_FREQ_1000HZ a fim de tirar máximo proveito do sensor.

3.3 Posição do sensor

A posição julgada como mais favorável para realizar os testes foi posicionando o sensor sobre o Biceps Brachii (Bíceps braquial), de acordo com a indicação SENIAM, mostrado na Figura 3, e observando diretamente no Serial Plotter as alterações de pico de acordo com o movimento ou ativação do músculo.

Figura 3 – Posição referência do sensor de eletromiografia de superfície no bíceps braquial.



Fonte: Disponível no site do SENIAM, Acesso em: 2 Jul. 2025.

A eletromiografia de superfície possui algumas desvantagens por ser não invasiva. Por depender unicamente de contato com a pele, acaba sendo difícil chegar em um bom resultado por fatores como o movimento do sensor, ruídos causados pela penugem do indivíduo e ruídos causados pela resistência relativa à pele e percentual de gordura. Esses ruídos geram uma incerteza na visualização dos dados, sendo difícil distinguir o que é um dado legítimo e o que é um ruído.

O bíceps braquial foi o músculo escolhido como referência para avaliação de desempenho do sensor por ser um músculo que apresenta menor porosidade capilar e percentual de gordura acumulado, seguindo as condições físicas do voluntário de teste (Autor).

3.4 Filtros

O exemplo fornecido na página do sensor de baixo custo é acompanhado de uma biblioteca externa nomeada como EMGFilters, a qual faz um tratamento dos dados com filtros passa-baixa em 150Hz, passa-alta em 20Hz e rejeita-banda na taxa de 50 a 60Hz. Já com o dispositivo New Miotool, foram aplicados os filtros passa-baixa em 500Hz e passa-alta em 20Hz.

3.5 Testes iniciais


Após a verificação do funcionamento do sensor e garantir que ele responde ao movimento, foram aplicados alguns testes que ajudam na identificação e classificação do que é ruído e o que é sinal verdadeiro.

O primeiro passo foi, através da linguagem de programação Python, criar um script capaz de coletar os dados vindos do sensor de baixo custo na comunicação serial e armazená-los em um arquivo .csv (dataset), o qual facilita a organização e manipulação com bibliotecas como NumPy, Pandas e Matplotlib. Além disso, foi utilizada a biblioteca spacy para os filtros passa-baixa, passa-alta, rejeita-banda, Transformada Rápida de Fourier e Transformada Contínua de Wavelet no decorrer dos testes.

Os dados coletados em formato .csv correspondem à uma série de movimentos de contração do bíceps braquial, do qual é possível retirar valores correspondentes à contração muscular máxima voluntária, a qual possibilita analisar média de ativação muscular, o pico de ativação muscular e a duração de contração, sendo esses os pontos comumente utilizados para a análise de eletromiografias.


Os gráficos do sensor de baixo custo sem filtros podem ser observados pelas Figuras 4 e 5:

Figura 4 – Gráfico de dados x tempo.



Fonte: elaborado pelo autor.

Figura 5 – Gráfico dados x índice.




Fonte: elaborado pelo autor.

O principal detalhe observável em ambos os gráficos, é que os valores são limitados em uma faixa do valor convertido pelo conversor AD de aproximadamente 3900, isso é por que o ESP32, como mencionado, possui em seus conversores AD um limite de resolução de 12 bits.

O padrão que o trabalho conseguiu obter como referência é dado pela Figura 6, que representa o sinal sEMG coletado pelo aparelho New Miotool:

Figura 6 – Sinal coletado pelo New Miotool.




Fonte: elaborado pelo autor.

Observando o sinal coletado pelo sensor da Miotec e comparando-o aos sinais puros coletados pelo Sen0240, é muito visível o nível de ruído que há de ser tratado no sensor de baixo custo.

Ao utilizar as configurações padrão da biblioteca EMGFilters, recomendada no exemplo oficial da página, obtém-se o gráfico mostrado na Figura 7.


Figura 7 – Sinal com filtros da biblioteca EMGFilters.



Fonte: elaborado pelo autor.

Observa-se que o sinal possui um comportamento diferente, isso acontece por que o tratamento feito no código oficial disponibilizado pela DFRobot, são aplicados os filtros mencionados na seção 3.4, e logo em seguida os dados são tratados com a função `sq()`, que os eleva ao quadrado, por isso existem apenas dados positivos. Entretanto, o uso dessa biblioteca, como pode ser visto, altera significativamente o valor de amplitude dos dados, tornando-os difícil de interpretar. Visto isso, os futuros testes terão como base o sinal obtido sem filtros, que, apesar de serem menos confiáveis pela limitação de resolução de bits, estão mais de acordo com o esperado de um sinal sEMG. Para isso, foi feito na linguagem de programação python, o tratamento dos dados de forma digital com filtros passa baixa em 450Hz, passa-alta em 20Hz, e rejeita-banda em 60Hz, o que resulta no sinal mostrado na Figura 8:

Figura 8 – Sinal filtrado com a biblioteca spicky.




Fonte: elaborado pelo autor.

3.5.1 Transformada Rápida de Fourier

Para verificar se os ruídos do sEMG de baixo custo são muito elevados, foi utilizado um dos pilares de análise de sinais, que é a Transformada Rápida de Fourier (FFT). A partir dela é possível transformar um sinal que está no domínio do tempo para um sinal no domínio da frequência, ou seja, ela diz quais frequências são mais presentes e mais intensas no sinal.

A Transformada Rápida de Fourier do sinal coletado é mostrada na Figura 9:


Figura 9 – Transformada Rápida de Fourier do sinal filtrado.



Fonte: elaborado pelo autor.


Analisando, é possível ver picos de frequência que não condizem com o esperado dos dados de eletromiografia, sendo eles, possivelmente, ruídos. Para amenizá-los, utilizando ainda a biblioteca *spicy*, foram aplicados filtros rejeita-banda nas frequências específicas aos ruídos, identificadas nos valores de 32-38Hz, 66-68Hz, 100-102Hz, 134-136Hz, 167-169Hz e por fim 235-237Hz. O que resulta nos gráficos mostrados nas Figuras 10 e 11:

Figura 10 – Sinal com filtros diversos.



Fonte: elaborado pelo autor.

Figura 11 – Transformada Rápida de Fourier do sinal, filtrando ruídos.



Fonte: elaborado pelo autor.

É evidente, após a remoção dos ruídos, que o sinal se torna muito mais fiel ao esperado de uma eletromiografia.

3.5.2 Operador de Energia de Teager-Kaiser

Outra ferramenta matemática utilizada neste trabalho para analisar a veracidade dos dados coletados pelo modelo de baixo custo é o operador de energia de Teager-Kaiser (TKEO), sendo essa utilizada para estimar a energia “instantânea” de um sinal, levando em conta a amplitude e a frequência instantânea.

Essa ferramenta na prática, combina uma amostra com a sua amostra anterior e posterior para estimar a energia, sendo capaz de capturar variações rápidas no sinal. A natureza de seu funcionamento filtra ruídos de baixa frequência, enfatizando o sinal da sEMG, sendo uma ótima ferramenta para analisar fadiga muscular, um parâmetro analisado no âmbito de reabilitação. A sua utilização em sinais digitais é dada de forma discreta, descrita por:


$$\Psi[x[n]] = x[n]^2 - x[n-1] \cdot x[n+1], \text{ onde:}$$

$x[n]$ = função relativa ao valor atual do dado na posição n

Ψ = energia teageriana

Através dessa ferramenta é possível analisar, na Figura 12, os momentos de ativação do músculo:

Figura 12 – Gráfico do TKEO do sinal sEMG.




Fonte: elaborado pelo autor.

3.5.3 Transformada Contínua de Wavelet

A Transformada Contínua de Wavelet (CWT) é outra ferramenta matemática que foi aplicada ao conjunto de dados retirados do protótipo de baixo custo por ter

propriedades fortes para análise de sinais não estacionários, como é o caso do EMG. O seu funcionamento é tal que um sinal é decomposto em em funções chamadas wavelets, que são ondas pequenas localizadas no tempo, sendo essa a sua principal característica, a possibilidade de analisar um sinal no domínio do tempo e no domínio da frequência simultaneamente, o que é visto em formato de espectrograma, como na Figura 13:

Figura 13 – Espectrograma de Wavelet do sinal sEMG.



Fonte: elaborado pelo autor.

3.5.4 Correlação de Spearman

Um parâmetro de avaliação amplamente utilizado para comparar a integridade dos sinais é a Correlação de Spearman, a qual avalia a relação monotônica entre os sinais, ou seja, avalia se os sinais seguem uma tendência semelhante. O seu funcionamento é dado de forma que um conjunto de dados é transformado em ranks (posições ordinais) e calcula-se a diferença entre os ranks de cada par de dados. Essa correlação é feita de acordo com a seguinte equação:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \text{ onde:}$$

ρ = coeficiente de Spearman;

n = número de pares;

d_i = diferença entre os ranks dos pares de dados.

Em resumo, ela é uma correlação fundamental que compara dois conjuntos de dados e avalia se a distribuição é parecida através de uma classificação que varia entre -1 e 1 para o Coeficiente de Spearman (ρ), sendo -1 a correlação perfeitamente decrescente e +1 a correlação perfeitamente crescente, o 0 por sua vez representa nenhuma relação monotônica. Esse método foi aplicado em cenários de comparação entre o sensor de baixo custo com e sem filtros (Figura 14), e será feito entre o sensor de baixo custo e o aparelho comercial padrão ouro.

Figura 14 – Resultado da correlação de Spearman entre dados com e sem filtros.

```
Coeficiente de Spearman: 0.3334
P-valor: 0.0000e+00
Correlação estatisticamente significativa.

(0.33338187028905353, 0.0)
```

Fonte: elaborado pelo autor.


O resultado de 0.333... indica uma correlação positiva fraca a moderada entre os sinais, que houve a redução da semelhança na ordem dos valores, porém, o que realmente importa, é que o P-valor atingiu algo muito próximo de zero, o que é muito bom, significa que os dados filtrados mantiveram a forma original.

3.6 Fundamentação teórica e trabalhos correlatos

A fundamentação teórica do presente trabalho tomou início pela pesquisa de trabalhos correlatos em base de dados como Capes CAFE, Scopus, Pubmed, IEEE e SciELO, todavia, apenas as três primeiras apresentaram uma quantidade considerável de publicações. A string de busca utilizada para a pesquisa nas bases de dados consiste de: ("Post surgery" OR "Surgery recovery" OR "Rehabilitation monitoring" OR "Postoperative" OR "Recovery Phase" OR "Physiotherapy") AND ("Disability" OR "Disabilities" OR "Muscle deficiency" OR "Health" OR "Health care" OR "Recovery" OR "Mobility" OR "Flexibility" OR "Rehabilitation") AND ("Myoelectric" OR "EMG" OR "Myography" OR "Electromyography") AND ("low cost" OR "Sensor" OR "Artificial Intelligence" OR "AI" OR "Machine learning" OR "Signal processing" OR "Application")", sendo os trabalhos filtrados por data entre os anos de 2020 até 2024.

A filtragem por duplicatas e fase de Screening (escolha dos artigos que abordam os assuntos tratados no trabalho) foram feitas utilizando a ferramenta [Rayyan.ai](https://www.rayyan.ai), o que pode ser verificado pelo seguinte "PRISMA Flow Diagram" (Figura 15):

Figura 15 – PRISMA Flow Diagram do trabalho



Fonte: elaborado pelo autor.

4 PROPOSTA PARA O TRABALHO DE CONCLUSÃO DE CURSO

Visto os testes realizados na seção 3, é notável que o modelo de baixo custo tem uma base de leitura de eletromiografia de superfície, porém, ele por si só, possui capacidades limitadas. O tratamento de ruídos ainda deve ser analisado com mais cuidado, pois as frequências rejeitadas também possuem dados reais, e não apenas ruídos.

Infelizmente, não foi possível realizar testes realmente significativos com o aparelho comercial por ele ser constantemente utilizado em clínicas com os professores do curso de Fisioterapia.

Outro ponto é que o sensor de baixo custo utilizado não é totalmente um baixo custo, então, há a possibilidade de dedicar um tempo de TCC 1 para avaliar outro sensor mais barato ou até mesmo a confecção de um sensor.

4.1 Problemas passíveis de solução

Como citado anteriormente, o ESP32 possui uma limitação na conversão de dados digitais para analógicos com um teto de resolução de 12 bits, a solução

proposta é utilizar um conversor AD externo que tenha resolução de 16 bits, que ainda é um circuito eletrônico barato, a fim de compará-lo diretamente ao aparelho comercial de padrão ouro.

O segundo ponto é que a qualidade do sinal, quando os detalhes como taxa de amostragem e ruídos são somados, não é tão preciso, então, uma proposta para retirar informações mais sólidas, seria a utilização de acelerômetros (sensores IMU), a fim de identificar o nível de movimento que a pessoa consegue executar. Isso tornará possível a observação de qual debilitação o movimento possui.

4.2 Retirar dados do aparelho comercial

Durante o semestre de 2025/1 houve a oportunidade de contatar professores do curso de Fisioterapia da UFSC e, com isso, houve a possibilidade de testar o aparelho comercial de forma bem resumida, pois o objetivo inicial era apenas verificar a aparência da resposta que o aparelho retornava. Dado isso, por o aparelho estava constantemente em uso nas clínicas, não foi possível realizar testes realmente fieis que possam servir como uma comparação aguda com o modelo de baixo custo, tornando isso, um objetivo para os semestres de TCC 1 e TCC 2, a análise de dados fundamentais do sensor comercial para que a comparação seja validada.

4.3 Fundamentação teórica

A fundamentação teórica descrita no documento até o momento é bastante rasa, então, para o trabalho de conclusão de curso, há de ser aprofundado os conceitos já citados e introduzir o restante dos temas, de forma que o trabalho tenha uma base forte.

4.4 Avaliação do sensor e uso em clínicas

Como objetivo final do projeto, tendo um sistema capaz de realizar leituras válidas de eletromiografia, a fase final é levar o sistema aos professores de graduação Alessandro Haupenthal e Daniela Pacheco dos Santos Haupenthal, ambos do curso de Fisioterapia, os quais já tive contato para tirar dúvidas sobre o uso de sEMG no cenário de reabilitação.

Em conversas durante o período de 2025/1, houve discussões sobre a necessidade de, em caso de o sensor ser validado e utilizado para coletar dados, criar um comitê de ética. A ideia inicial é integrar o trabalho à um dos projetos do professor Alessandro, o qual já possui um comitê de ética para o uso de sensores em clínicas. Caso a ideia seja inviável, a opção restante é criar um comitê de ética no início do semestre 2025/2, para que haja tempo suficiente para a possível aprovação e que sobre tempo para coletar dados.

Objetivo geral: Desenvolvimento durante TCC 2															
Ação	Semanas														
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	
1. Retomar estudos relacionados	x	x	x												
2. Avaliar mudanças necessárias no sistema		x	x	x											
3. Uso em clínicas (caso possível)			x	x	x	x	x	x	x	x					
4. Avaliação da ferramenta de IA						x	x	x	x	x					
5. Escrita do documento			x	x	x	x	x	x	x	x	x	x			
6. Finalização do documento												x	x		
7. Finalização e apresentação do trabalho													x	x	

6 CONSIDERAÇÕES FINAIS

O presente trabalho é uma introdução do trabalho de conclusão de curso, que teve como objetivo tomar um pontapé inicial do desenvolvimento e fundamentação teórica da validação de um sensor de eletromiografia de baixo custo para uso em fase de reabilitação, visando oferecer uma alternativa acessível a aparelhos comerciais. Além disso, utilizando os dados captados pelo Sen0240 e ESP32 com o padrão SENIAM, apresentou diversas ferramentas digitais e matemáticas que tratam os ruídos, como filtros digitais, FFT, TKEO, CWT e Correlação de Spearman. Por fim, é visto que a eletromiografia é uma técnica muito importante para diagnósticos mais precisos, e que o uso do sensor proposto ainda não é totalmente viável, então, o trabalho propõe sugestões para o período referente a TCC1 e TCC 2, definindo um caminho a ser seguido e as avaliações necessárias com uso de conversores AD externos, IMUs, melhores comparações com o aparelho comercial de referência, o uso em clínicas e a integração com inteligência artificial para que a eficiência do tratamento na reabilitação seja melhorado.

REFERÊNCIAS

- AGOSTINI, Valentina *et al.* Surface Electromyography Applied to Gait Analysis: How to Improve Its Impact in Clinics? **Frontiers in Neurology**, v. 11, p. 994, 4 set. 2020.
- ALCAN, Veysel; ZİNNUROĞLU, Murat. Current developments in surface electromyography. **Turkish Journal of Medical Sciences**, v. 53, n. 5, p. 1019–1031, 26 out. 2023.
- BACHO, M. S. Heiqal *et al.* IoT-Based Multi-Level Sensors Electromyography (EMG) Acquisition System. *In*: 2023 IEEE INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE IN ENGINEERING AND TECHNOLOGY (IICAET). **2023 IEEE International Conference on Artificial Intelligence in Engineering and Technology (IICAET)**. Kota Kinabalu, Malaysia: IEEE, 12 set. 2023. Disponível em: <<https://ieeexplore.ieee.org/document/10291756/>>. Acesso em: 30 jun. 2025
- BAWA, Anthony; BANITSAS, Konstantinos. Design Validation of a Low-Cost EMG Sensor Compared to a Commercial-Based System for Measuring Muscle Activity and Fatigue. **Sensors**, v. 22, n. 15, p. 5799, 3 ago. 2022.
- BOYER, Marianne *et al.* Reducing Noise, Artifacts and Interference in Single-Channel EMG Signals: A Review. **Sensors**, v. 23, n. 6, p. 2927, 8 mar. 2023.
- CAMPANINI, Isabella *et al.* Surface EMG in Clinical Assessment and Neurorehabilitation: Barriers Limiting Its Use. **Frontiers in Neurology**, v. 11, p. 934, 2 set. 2020.
- DE OLIVEIRA NASCIMENTO, Francisco Assis; DE ARAÚJO ROCHA, Valdinar; DO CARMO, Jake Carvalho. Scalable weighted-cumulated methodology for fatigue estimation. **Research on Biomedical Engineering**, v. 38, n. 4, p. 1087–1101, 17 set. 2022.
- DELGADO-TORRES, Juan C. *et al.* Development of a Low-Cost Interactive Prototype for Acquisition and Visualization of Biosignals. *In*: ICSEE 2024. **ICSEE 2024**. MDPI, 25 nov. 2024. Disponível em: <<https://www.mdpi.com/2673-4591/82/1/1>>. Acesso em: 30 jun. 2025
- DOST SÜRÜCÜ, Gülseren; TEZEN, Özge. The effect of EMG biofeedback on lower extremity functions in hemiplegic patients. **Acta Neurologica Belgica**, v. 121, n. 1, p. 113–118, fev. 2021.
- FALIAGKA, Evanthia *et al.* Leveraging Edge Computing ML Model Implementation and IoT Paradigm towards Reliable Postoperative Rehabilitation Monitoring. **Electronics**, v. 12, n. 16, p. 3375, 8 ago. 2023.
- FALKOWSKI, Piotr *et al.* Method of automatic biomedical signals interpretation for safety supervision and optimisation of the exoskeleton-aided physiotherapy of lower extremity. *In*: ROBCE 2024: 2024 4TH INTERNATIONAL CONFERENCE ON ROBOTICS AND CONTROL ENGINEERING. **Proceedings of the 2024 4th International Conference on Robotics and Control Engineering**. Edinburgh

United Kingdom: ACM, 27 jun. 2024. Disponível em:
<<https://dl.acm.org/doi/10.1145/3674746.3674793>>. Acesso em: 30 jun. 2025

FARINA, Dario; MERLETTI, Roberto; ENOKA, Roger M. The extraction of neural strategies from the surface EMG: 2004–2024. **Journal of Applied Physiology**, v. 138, n. 1, p. 121–135, 1 jan. 2025.

FENG, Jirou *et al.* Design of a Flexible High-Density Surface Electromyography Sensor. *In*: 2020 42ND ANNUAL INTERNATIONAL CONFERENCE OF THE IEEE ENGINEERING IN MEDICINE AND BIOLOGY SOCIETY (EMBC) IN CONJUNCTION WITH THE 43RD ANNUAL CONFERENCE OF THE CANADIAN MEDICAL AND BIOLOGICAL ENGINEERING SOCIETY. **2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)**. Montreal, QC, Canada: IEEE, jul. 2020. Disponível em:
<<https://ieeexplore.ieee.org/document/9175484/>>. Acesso em: 27 jun. 2025

FUENTES DEL TORO, Sergio *et al.* Validation of a Low-Cost Electromyography (EMG) System via a Commercial and Accurate EMG Device: Pilot Study. **Sensors**, v. 19, n. 23, p. 5214, 28 nov. 2019.

GARCIA, Gabriel J. *et al.* ARMIA: A Sensorized Arm Wearable for Motor Rehabilitation. **Biosensors**, v. 12, n. 7, p. 469, 29 jun. 2022.

GONG, Qibei *et al.* A Flexible Wireless sEMG System for Wearable Muscle Strength and Fatigue Monitoring in Real Time. **Advanced Electronic Materials**, v. 9, n. 9, p. 2200916, set. 2023.

GONZALES-HUISA, Omar A. *et al.* EMG and IMU Data Fusion for Locomotion Mode Classification in Transtibial Amputees. **Prosthesis**, v. 5, n. 4, p. 1232–1256, 21 nov. 2023.

HALL, John E. **Tratado de fisiologia médica**. [S.l.]: Elsevier, 2015.

HAUFE, Stefan *et al.* Gait Event Prediction Using Surface Electromyography in Parkinsonian Patients. **Bioengineering**, v. 10, n. 2, p. 212, 6 fev. 2023.

HEYWOOD, Sophie *et al.* Low-cost electromyography – Validation against a commercial system using both manual and automated activation timing thresholds. **Journal of Electromyography and Kinesiology**, v. 42, p. 74–80, out. 2018.

ISMAIL, Rifky. Muscle Power Signal Acquisition Monitoring Using Surface EMG. **Journal of Biomedical Research & Environmental Sciences**, v. 3, n. 5, p. 663–667, maio 2022.

J. M. DICK, Taylor *et al.* Consensus for experimental design in electromyography (CEDE) project: Application of EMG to estimate muscle force. **Journal of Electromyography and Kinesiology**, v. 79, p. 102910, dez. 2024.

JARCHI, Delaram *et al.* A Review on Accelerometry-Based Gait Analysis and Emerging Clinical Applications. **IEEE Reviews in Biomedical Engineering**, v. 11, p.

177–194, 2018.

JERO, S. Edward; BHARATHI, K. Divya; RAMAKRISHNAN, S. A Method to Differentiate Fatiguing Conditions in Surface Electromyography Signals using Instantaneous Spectral Centroid. *In: 2020 42ND ANNUAL INTERNATIONAL CONFERENCE OF THE IEEE ENGINEERING IN MEDICINE AND BIOLOGY SOCIETY (EMBC) IN CONJUNCTION WITH THE 43RD ANNUAL CONFERENCE OF THE CANADIAN MEDICAL AND BIOLOGICAL ENGINEERING SOCIETY. 2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*. Montreal, QC, Canada: IEEE, jul. 2020. Disponível em: <<https://ieeexplore.ieee.org/document/9176599/>>. Acesso em: 30 jun. 2025

KINUGASA, Ryuta; KUBO, Shimpei. Development of Consumer-Friendly Surface Electromyography System for Muscle Fatigue Detection. **IEEE Access**, v. 11, p. 6394–6403, 2023.

LI, Chengyu *et al.* Deep Learning Model Coupling Wearable Bioelectric and Mechanical Sensors for Refined Muscle Strength Assessment. **Research**, v. 7, p. 0366, jan. 2024.

LIANG, Ruixin *et al.* Electromyographic Analysis of Paraspinal Muscles of Scoliosis Patients Using Machine Learning Approaches. **International Journal of Environmental Research and Public Health**, v. 19, n. 3, p. 1177, 21 jan. 2022.

LIU, Xing-kai *et al.* Integrating surface electromyography into physical therapy training with the support of STEM education. **Frontiers in Neurology**, v. 15, p. 1501619, 21 nov. 2024.

LUCAS, Mateus Gomes *et al.* Avaliação de métodos adaptativos e baseados em software para compensação de artefato de estímulo em sEMG. **Revista Brasileira de Física Médica**, v. 13, n. 2, p. 53, 28 dez. 2019.

LUCAS, Mateus Gomes. UNIVERSIDADE FEDERAL DE SANTA CATARINA CAMPUS FLORIANÓPOLIS PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA. 2023.

MACHETANZ, Kathrin *et al.* Design and Evaluation of a Custom-Made Electromyographic Biofeedback System for Facial Rehabilitation. **Frontiers in Neuroscience**, v. 16, p. 666173, 4 mar. 2022.

MANZUR-VALDIVIA, Hachi; ALVAREZ-RUF, Joel. Surface Electromyography in Clinical Practice. A Perspective From a Developing Country. **Frontiers in Neurology**, v. 11, p. 578829, 15 out. 2020.

MASHAYEKHI, Maryam; MOGHADDAM, Majid M. EMG-driven fatigue-based self-adapting admittance control of a hand rehabilitation robot. **Journal of Biomechanics**, v. 138, p. 111104, jun. 2022.

MCMANUS, Lara; DE VITO, Giuseppe; LOWERY, Madeleine M. Analysis and Biophysics of Surface EMG for Physiotherapists and Kinesiologists: Toward a

Common Language With Rehabilitation Engineers. **Frontiers in Neurology**, v. 11, p. 576729, 15 out. 2020.

MERLETTI, R.; CERONE, G. L. Tutorial. Surface EMG detection, conditioning and pre-processing: Best practices. **Journal of Electromyography and Kinesiology**, v. 54, p. 102440, out. 2020.

MERLETTI, Roberto *et al.* Technology and instrumentation for detection and conditioning of the surface electromyographic signal: State of the art. **Clinical Biomechanics**, v. 24, n. 2, p. 122–134, fev. 2009.

MERLETTI, Roberto *et al.* Translation of surface electromyography to clinical and motor rehabilitation applications: The need for new clinical figures. **Translational Neuroscience**, v. 14, n. 1, p. 20220279, 14 mar. 2023.

PAOLETTI, Michele *et al.* Electromyography Pattern Likelihood Analysis for Flexion-Relaxation Phenomenon Evaluation. **Electronics**, v. 9, n. 12, p. 2046, 2 dez. 2020.

PAPAGIANNIS, Georgios I. *et al.* Methodology of surface electromyography in gait analysis: review of the literature. **Journal of Medical Engineering & Technology**, v. 43, n. 1, p. 59–65, 2 jan. 2019.

PÉREZ-REYNOSO, Francisco *et al.* Pattern Recognition of EMG Signals by Machine Learning for the Control of a Manipulator Robot. **Sensors**, v. 22, n. 9, p. 3424, 30 abr. 2022.

PORTERO, Pierre *et al.* Surface Electromyography in Physiotherapist Educational Program in France: Enhancing Learning sEMG in Stretching Practice. **Frontiers in Neurology**, v. 11, p. 584304, 3 dez. 2020.

QAMAR, Hafiz Ghulam Murtza *et al.* EMG gesture signal analysis towards diagnosis of upper limb using dual-pathway convolutional neural network. **Mathematical Biosciences and Engineering**, v. 21, n. 4, p. 5712–5734, 2024.

SANTOSH, Vamsi E. *et al.* Electromyographic evaluation of masseter and temporalis muscle activity after periodontal surgery: A prospective clinical trial. **Journal of Taibah University Medical Sciences**, v. 18, n. 2, p. 356–365, abr. 2023.

SEO, Jeong-Woo; KIM, Hyeong-Sic. Biomechanical Analysis in Five Bar Linkage Prototype Machine of Gait Training and Rehabilitation by IMU Sensor and Electromyography. **Sensors**, v. 21, n. 5, p. 1726, 2 mar. 2021.

SETHI, Amit *et al.* Advances in motion and electromyography based wearable technology for upper extremity function rehabilitation: A review. **Journal of Hand Therapy**, v. 33, n. 2, p. 180–187, abr. 2020.

SILVA JUNIOR, Emanuel Fernandes Ferreira Da *et al.* Surface electromyography signal processing and evaluation on respiratory muscles of critically ill patients: A systematic review. **PLOS ONE**, v. 18, n. 4, p. e0284911, 27 abr. 2023.

SIWADAMRONGPONG, Wigran *et al.* Fall Detection and Prediction Based on IMU and EMG Sensors for Elders. *In: 2022 19TH INTERNATIONAL JOINT CONFERENCE ON COMPUTER SCIENCE AND SOFTWARE ENGINEERING (JCSSE). 2022 19th International Joint Conference on Computer Science and Software Engineering (JCSSE)*. Bangkok, Thailand: IEEE, 22 jun. 2022. Disponível em: <<https://ieeexplore.ieee.org/document/9836284/>>. Acesso em: 27 jun. 2025

STANKOVIĆ, Emilija; MARČEK, Deni. Comparative Analysis of Hand Movements: A Research Study of Individual with Brachial Plexus Palsy. *In: 2024 11TH INTERNATIONAL CONFERENCE ON ELECTRICAL, ELECTRONIC AND COMPUTING ENGINEERING (ICETRAN). 2024 11th International Conference on Electrical, Electronic and Computing Engineering (IcETRAN)*. Nis, Serbia: IEEE, 3 jun. 2024. Disponível em: <<https://ieeexplore.ieee.org/document/10645139/>>. Acesso em: 30 jun. 2025

TANWEER, Muhammad; HALONEN, Kari A. I. Development of wearable hardware platform to measure the ECG and EMG with IMU to detect motion artifacts. *In: 2019 IEEE 22ND INTERNATIONAL SYMPOSIUM ON DESIGN AND DIAGNOSTICS OF ELECTRONIC CIRCUITS & SYSTEMS (DDECS). 2019 IEEE 22nd International Symposium on Design and Diagnostics of Electronic Circuits & Systems (DDECS)*. Cluj-Napoca, Romania: IEEE, abr. 2019. Disponível em: <<https://ieeexplore.ieee.org/document/8724639/>>. Acesso em: 30 jun. 2025

TONELLO, Sarah *et al.* Preliminary Study of a Flexible Printed Multi-Sensing Platform for Electromyography and Lactate Measuring during Rehabilitation. *In: 2021 IEEE INTERNATIONAL SYMPOSIUM ON MEDICAL MEASUREMENTS AND APPLICATIONS (MEMEA). 2021 IEEE International Symposium on Medical Measurements and Applications (MeMeA)*. Lausanne, Switzerland: IEEE, 23 jun. 2021. Disponível em: <<https://ieeexplore.ieee.org/document/9478729/>>. Acesso em: 30 jun. 2025

TRZMIEL, Tomasz *et al.* The Effect of Using a Rehabilitation Robot for Patients with Post-Coronavirus Disease (COVID-19) Fatigue Syndrome. **Sensors**, v. 23, n. 19, p. 8120, 27 set. 2023.

UNIVERSITI TEKNOLOGI MALAYSIA *et al.* A Smart Iot-Based Prototype System For Rehabilitation Monitoring. **International Journal of Integrated Engineering**, v. 15, n. 3, 31 jul. 2023.

VAROL, Umut *et al.* Convergent Validity between Electromyographic Muscle Activity, Ultrasound Muscle Thickness and Dynamometric Force Measurement for Assessing Muscle. **Sensors**, v. 23, n. 4, p. 2030, 10 fev. 2023.

WEI, Wenhao *et al.* Surface electromyogram, kinematic, and kinetic dataset of lower limb walking for movement intent recognition. **Scientific Data**, v. 10, n. 1, p. 358, 6 jun. 2023.

YASSIN, Mazen M. *et al.* Developing a Low-cost, smart, handheld electromyography biofeedback system for telerehabilitation with Clinical Evaluation. **Medicine in Novel**

Technology and Devices, v. 10, p. 100056, jun. 2021.

ZHU, Pengdong *et al.* Deep Learning-Based Surface Nerve Electromyography Data of E-Health Electroacupuncture in Treatment of Peripheral Facial Paralysis.

Computational and Mathematical Methods in Medicine, v. 2022, p. 1–12, 31 maio 2022.